


Поиск по картинке / поиск на картинках. Оценка проекта до взятия в работу

1) Оценка потенциала проекта. Как часто возникает проблема? Оценка экономического эффекта

Проблема: пользователи маркетплейсов и интернет-магазинов не могут найти нужный товар через текстовый поиск, потому что не знают, как его описать словами. Они видели предмет вживую, на фото в соцсетях, в фильме или у знакомых - но не знают ни бренда, ни названия, ни правильной категории. Некоторые цифры: **52% покупателей** затрудняются описать словами то, что ищут ([Pinterest & Retail Week, опрос 1 000 покупателей в Великобритании, 2025](#)); **>85% онлайн-покупателей** считают визуальную информацию более важной, чем текстовую при покупке одежды или мебели ([Shopify, 2023](#))

How likely are consumers to discover new products online through visual search and images over the next 12 months?



([Pinterest & Retail Week, опрос 1 000 покупателей в Великобритании, 2025](#))

С точки зрения экономического эффекта, ожидается рост конверсии и рост просмотров товаров за сессию. В перспективе - снижение операционных расходов на каталогизацию и снижение возвратов.

2) Есть ли простое решение?

Ключевая ценность визуального поиска - возможность искать картинкой по каталогу или текстом по изображениям. Простые решения (поиск по ключевым словам, BM25, фильтры по атрибутам) принципиально не способны уловить семантику запроса, если она расходится с тем, что написал продавец. Такие запросы требуют кросс-модального понимания, модель должна сопоставить текст именно с тем, что изображено на фото, а не с тем, что написал продавец.

Типичные случаи, где текстовый поиск не работает:

- Когда важная деталь присутствует только на изображении (например, принт на одежде - «футболка с котиком»)
- Когда запрос описывает форму или фасон, который продавец не указал (например, «платье с рукавом-фонариком»)
- Когда используются визуальные или субъективные характеристики (например, «кеды на толстой подошве», «oversize»)

Вывод: Во всех примерах проблема одинакова: релевантная информация присутствует на изображении, но отсутствует в текстовых данных. Это делает текстовый поиск неполным. Задача требует ML-подхода.

3) Реалистичность решения с помощью ML

Существуют десятки успешных продуктов, использующих визуальный поиск: Pinterest Lens, Google Lens, ASOS Style Match, Amazon StyleSnap. Один из основных подходов – мультимодальная модель, реализующая контрастивный лосс. Контрастивная функция потерь притягивает друг к другу эмбединги запроса и позитивного примера, в то же самое время отталкивая эмбединги негативных примеров; тем самым она реализует единое векторное пространство для картинок и текстов. Такая сеть будет способна ранжировать по метрике схожести визуальные и текстовые концепции

QUERY PIPELINE

- Изображение -> CLIP/SigLIP -> Embedding (768-1024d)
- Текст -> CLIP/SigLIP -> Embedding (768-1024d)

ANN INDEX

- 1M+ товарных эмбедингов, предрасчитанных оффлайн
- Approximate Nearest Neighbor search, top-K
- Опционально - Re-ranker (кросс-энкодер или согласно каким-то бизнес правилам (цена, наличие ...))

4) Технические требования

Сервис должен отвечать за < 1 сек, и держать нагрузку 1 gps. Конечные технические требования очень сильно зависят от архитектурных решений:

- Размерность эмбедингов
- Выбор реализации ANN
- Стратегия квантования
- Размер выбранной модели
- Наличие и выбор ре-ранкера